

基于三维关系模型和决策树回归的 NIPT 时点的策略研究

摘要

NIPT 是一种无创产前检测,但这种检测的准确性不能够保证,会根据孕妇个人特征以及实际的检测条件有着较大波动。本文通过建立三维关系模型探究染色体浓度与其他指标的相关关系,以最小化孕妇风险为核心目标,找到了最佳分组和最佳检测时点。

针对问题一,本文进行了数据的预处理,修改数据的错误值,过滤测序失败的数据。首先进行相关性分析,建立三维度关系模型。首先是基于线性相关性分析的第一维度的线性关系探索。其次基于本题的数据特征本文创新提出“蒙特卡洛+灰色预测”的组合关系预测模型,进行第二维度的探索,得到关系预测方程式,接着使用后验差检验,计算得到的 C 值为 1.201, P 值为 0.418。发现模型的显著性较弱。鉴于医学检测数据可能存在非独立性,且指标间关系可能呈现非线性特征,引入了更先进的机器学习方法 XGBoost,探寻第三维度的关系,以应对复杂情况。在 $\alpha = 0.05$ 的显著性水平下,单变量具备较好的显著性水平,但是组合变量不具备显著性。进行测试发现其精度较低,无法说明其具有较好的显著性。得到结论,这些指标变量之间具有难以捕捉的复杂非线性关系。

针对问题二,要求根据 BMI 进行合理分组,并且找到每个最别的最佳检测时间以达到最小化风险的目标。两个核心任务:分组和优化。本文采用决策树回归的方法,输入的特征自动寻找到最佳分裂点,形成分组区间,并且能够预测目标变量,从而为每组推荐最佳的 NIPT 时点。最终分出了 6 个小组:(26.2, 29]、(29.0, 30.3]、(30.3, 31.1]、(31.1, 34.6]以及 $BMI > 34.6 \& \text{年龄} \leq 29.5$ 、 $BMI > 34.6 \& \text{年龄} > 29.5$ 。这六个组对应的相对孕周的最佳时间点的非整数值为 20.32w、16.27w、20.71w、19.57w、21.7w、20.41w。使用蒙特卡洛算法模拟检测误差,模型的显著性不明显。

针对问题三,问题三是问题二的延伸,需要考虑更加全面的 Y 染色体浓度的影响因素,同时还要考虑其他因素的限制。本文仍在决策树的基础上进行模型拓展,使用决策树进行风险分组,使用随机森林进行组内随机优化与预测。最后结合蒙特卡洛对模型进行验证以及检验误差分析。最终给出了 5 个分组,其中组别 1 和组别 4 的分组特征和最佳检测时点为:

组1: {检测孕周数值 $\leq 17.43 \& \text{体重} \leq 87.25 \& \text{孕妇 BMI} \leq 29.40$ } 最佳时间: 12.36w

组4: {检测孕周数值 $> 17.43 \& \text{体重} \leq 98.45kg \& \text{年龄} \leq 35.00$ } 最佳时间: 17.57w

该模型的最佳交叉验证分数值为 0.8013,测试集准确率为 83.33%。模型有较强的显著性。

针对问题四,属于有监督的分类问题。首先对女胎孕妇的 NIPT 数据开展初步分析,构建一种初阶的分类方法:当 X 染色体浓度落在 $(-0.066, -0.048)$ 时,女胎必然是异常的,且一定存在 18 号非整倍体;当 X 染色体浓度在 $(0.024, 0.13)$ 时,女胎必然是正常的。对于其他情况,12 个指标之间与异常结果的关系是复杂的,本文使用 BP 神经网络融合蒙特卡洛建立二阶分类模型,训练出来了分类模型,并且通过模型测试,平均准确率为 0.6991,平均召回率为 0.9810。说明模型的性能良好。

关键词: 三维关系模型 蒙特卡洛 决策回归 决策数分类 随机森林 BP 神经网络

一、问题重述

1.1 问题背景

孕妇从怀孕到生产，确定胎儿的健康状况、保障孕妇的安全是必要且重要的。NIPT（无创产前检测技术），通过采集母体血液、检测胎儿的游离的 DNA 片段，进而分析孕妇腹中胎儿的染色体是否存在异常。但是根据实际检测发现，NIPT 的结果不一定完全准确，检测结果的准确性跟胎儿的性染色体浓度高度相关。在 10 周到 25 周之间进行产检，并且：（1）当男胎的 Y 染色体浓度不小于 4%；（2）女胎的 X 染色体浓度没有异常。可以认为该技术的准确性较高，检测结果是值得信赖的。临床实践发现，男胎的 Y 染色体浓度与孕妇孕周数以及 BMI 有较为紧密的关系。本文的研究的核心内容就是要根据孕妇的 BMI 进行分组，确定好每一组的检测时间点。尽可能减小孕妇的风险，保障孕妇的生产安全。总结来说，（1）要尽早发现；（2）检测结果要尽可能准确。

附件数据说明：（1）男胎孕妇的 NIPT 数据；（2）女胎孕妇的 NIPT 数据。检测数据分为两种类别：多次多检和一次一检，记录了每一个孕妇的基本指标以及每次检测结果。




图 1 问题背景解释图

1.2 问题要求

本文需要在上述背景下，分析附件数据，建立数学模型，需要确定好核心的孕妇的最佳 NIPT 检测时间点。具体来说，要解决以下具体问题：

1.2.1 问题一

问题一要求，分析男胎的 Y 染色体浓度与孕妇的孕周数和孕妇的 BMI 等指标的相关关系特性，进一步给出对应的关系模型，最后需要检验该模型的显著性与准确性。

1.2.2 问题二

问题二要求，首先已知男胎孕妇的 BMI 是影响男胎 Y 染色体浓度最早达标时间的主要因素，我们首先要根据孕妇的 BMI 的进行合适的分组，然后确定好每组的最佳 NIPT 检测时间点，核心目标是最小化孕妇的潜在风险。最后我们需要分析检测误差对结果的影响。

1.2.3 问题三

问题三是问题二的进一步延伸，区别于问题二“仅关注个体达标”，需确保每组孕妇在候选时点的“群体达标比例”（Y 浓度 $\geq 4\%$ 的样本占比）达到临床可接受水平，避免时点过早导致多数人未达标；问题三需要进一步考虑影响男胎 Y 染色体浓度的其他因素。综合考虑孕妇的身高、体重、年龄、检测误差等其他因素。根据 BMI 进行合理的分组，并且给出每一组的最佳 NIPT 时间点，核心目标仍然是使得孕妇风险最小。最后分析检测误差对结果的影响。

1.2.4 问题四

前三个问题已经可以解决男胎孕妇的 NIPT 时间点，问题四要求我们给出女胎异常的判定方法。全面考虑 X 染色体以及 21 号、18 号、13 号染色体的 Z 值、GC 含量、读段数及相关比例、BMI 等因素，给出女胎异常的判定方法。最终是根据女胎孕妇的 21 号、18 号、13 号染色体非整倍体为判定结果，也就是女胎数据的 AB 列的结果，空白即为正常。

二、问题分析

本题主要就是通过分析附件数据,结合题目的背景知识,研究各类孕妇群体合适的 NIPT 时点,并且要对我们的模型求解结果的准确性进行分析。问题一是问题二三的预备,问题二和问题三是本文的核心任务,两者具有延伸性和拓展性。问题一二三都是基于附件的中男胎孕妇的 NIPT 数据进行分析的,问题四是基于附件中的女胎孕妇的 NIPT 数据进行分析的。

2.1 针对问题一

除了明确纳入 BMI 和孕周数这两个指标外,广泛查阅医学文献,引入更多指标,为模型搭建提供更丰富的选择。为探寻这些医学检测指标与胎儿 Y 染色体之间的关系,我们分阶段、多维度开展分析。建立三维关系探索模型。首先,从数据本身出发,探索每个指标与 Y 染色体浓度的单独关联。绘制散点图,初步判断是否存在线性拟合趋势,以此了解第一维度的关系。接着,运用相关性分析和灰色关联度分析,深入挖掘指标与 Y 染色体浓度的关联特性。通过灰色关联分析,依据各指标与 Y 染色体浓度(母序列)关联度的大小进行排序,筛选出关键影响因子。考虑到数据样本量较小,我们采用灰色预测构建第二维度的关系模型,并输出预测方程。然而,由于数据不具备相互独立性,我们融入其他方法,以提升模型的准确性。对于构建的关系模型,显著性检验必不可少。针对灰色预测,后验差检验是合理之选。更进一步思考,鉴于医学检测数据可能存在非独立性,且指标间关系可能呈现非线性特征,我们会引入更先进的机器学习方法,探寻第三维度的关系,以应对复杂情况。在每一维度的关系模型构建过程中,都将严格进行显著性检验,确保模型的可靠性和有效性,为医学研究和临床应用提供更坚实的支持。

2.2 针对问题二

问题二要求我们选择合理的 BMI 分组,以及对于每个组给出最佳的检测时间。看似是一个优化问题,但是该题难找到直接量化的优化方程表达式,想要直接建立优化模型可行性较低。我们首先量化分析优化目标(风险最小),再选择合适的方法。决策树是一种常见的分类方法,发现决策树回归可以达到我们的要求。决策树回归是一种监督学习方法,它可以根据输入的特征自动寻找到最佳分裂点,形成分组区间,并且能够预测目标变量,从而为每组推荐最佳的 NIPT 时点。通过该模型可以输出分组区间以及最佳检测时间点。题目还要求分析检验误差对结果的影响,在模型建立后先分析检验误差,计算检验误差的正确性

2.3 针对问题三

问题三仍是给男胎孕妇的 BMI 进行合适的分组,并且给出每组的最佳 NIPT 时间点。问题三是问题二的延伸。首先相比于问题二中只考虑 BMI 作为影响 Y 染色体浓度最早达标浓度,问题三还需要考虑年龄、身高、体重等因素作为影响孕妇 Y 染色体浓度达标最早时间的影响因子。其次问题三还需要综合考虑检测误差、胎儿的 Y 染色体浓度达标比例。那那么还是选择决策树作为分类,使用随机森林进行组内随机优化与预测。最后结合蒙特卡洛对模型进行验证以及检验误差分析。

2.4 针对问题四

题目中提供了多个维度的指标,这些指标将作为分类模型输入层的关键要素。由于已知分类结果,此过程属于有监督的判别分类任务,重点在于深入挖掘多指标与分类结果之间的内在关系,最终获取有效的判别方法。首先,对女胎孕妇的 NIPT 数据开展初步分析,试图构建一种初步的分类方法。然而,众多检测数据之间存在交叉关联,同时还受到误差干扰。这使得简单的初分类方法难以满足准确判定的需求,因此必须进一步探究多指标之间的复杂关系,以获取更为可靠的判别方法。综合考量,决定采用 BP 神经网络来训练分类模型。借助 BP 神经网络强大的非线性映射能力和学习能力,有望捕捉到多指标与女胎异常分类结果之间的微妙关系,从而构建出高效、准确的判别方法,为女胎异常的识别提供有力支持。

三、模型假设与符号说明

3.1 模型假设

为实现实际问题向数学模型的有效转化,本文首先提出以下模型假设(此为构建有效数学模型的关键前提与基础):

假设 1: 数据中的不同孕妇的 NIPT 检验是独立的

假设 2: 题目所选的指标对研究具有代表性

假设 3: 认为 13 号、21 号、18 号染色体的浓度可以由相应的染色体 Z 值表示

假设 4: 假设 GC 值在不在[0.4,0.6]的范围内为低质量数据

假设 5: Y 染色体浓度的主要影响因素为孕妇 BMI

假设 6: 女胎数据集覆盖全面,若满足基本规则,则视为无极端情况

对于上述假设,本文将在后续建模环节结合具体分析进行补充说明;此外,针对其中有关键影响的部分假设,需通过“敏感性分析”开展稳健性验证,明确假设微小扰动对模型输出结果的影响程度。

3.2 符号说明

受限于篇幅,本文在此仅呈现建模过程中涉及的核心符号;关于各符号的详细定义与使用场景,将在后续具体模型构建环节补充说明。

符号	解释说明
R_j	检测时间风险值
r_i	单次检验时间风险系数
D_i	检验准确率
b_j	BMI 区间下界
B_j	BMI 区间上界
S_i	患病风险值
	患病风险系数
s_i	$s_i = \begin{cases} 0, \text{胎儿健康} \\ 1, \text{检测出染色体异常且胎儿不健康} \\ 2, \text{未检测出染色体异常但胎儿不健康} \end{cases}$
	检测准确度
ω_i	$\omega_i = \begin{cases} 1, \text{检出非整倍体情况与健康状况吻合} \\ 0, \text{检出非整倍体情况与健康状况不吻合} \end{cases}$

四、概念说明与数据预处理

上一节本文已经分析了题目的背景信息和基本要求，建模的核心是要确定好 NIPT 的时间点以及胎儿异常的判定方法，考虑到题目是建立在较为复杂的生物医学背景之下，本文首先要对题目所给的附件数据进行深入探索和理解，把握数据的结构和解释说明，才能够保证对题目有着深刻的思考，这是为后续建立关系模型和优化模型做铺垫。

本题给出的附件数据是某地区孕妇的 NIPT 数据，包含两个表格，一个是男胎的孕妇数据，另外一个为女胎孕妇的数据。附录中给出了 31 个列署的说明。我们首先要结合数据表格将题目中涉及到的测检准则、NIPT 准确性判定方法、患病条件判断做出具体说明，只有明确了以下概念，我们才能够对题目理解透彻，整理合适的的数据带入后续模型进行求解计算。

4.1 概念的明晰及数据分类

(1) 测序质量的判断

题目中说到在实际的检测中，可能会由于检测时间选择不对或者是其他因素的影响，导致测序质量较差，也就是说，并没有成功进行测序。如何判断这个测序质量是否合格（是否成功进行了测序），附录中说明，可以根据 P 列的“GC 含量”来判断测序质量是否存在问题。当 GC 含量在[0.4,0.6]这个范围之内，我们可以下结论，该孕妇成功进行了 NIPT。只有在成功进行了检测的前提下，我们才能够继续讨论 NIPT 的准确性的问题。当 GC 含量较低，测序质量不合格，说明没有成功进行了 NIPT，那么继续讨论 NIPT 的准确性是没有意义的。

(2) NIPT 准确性判定方法

NIPT 是一种当前较为流行的产前检测手段，可以分析胎儿染色体是否存在异常。根据实际经验，所有的检测手段的准确性不能够达到 100%，也就是说成功进行了 NIPT（上面所说的测序质量合格），这个检测结果的准确性也是有待商讨的。题目给出了 NIPT 准确性的判断方法，在孕妇的孕期在 10 周到 25 周之间可以检测胎儿的性染色体浓度，在这个前提下，如果男胎的 Y 染色体浓度不低于 0.04 或者女胎的 X 染色体浓度没有异常，我们可以说明本次 NIPT 的准确性较高，这个检测结果是采纳的。

(3) 患病条件及 Z 值的理解

题目说到，三种畸形胎儿体征的是分别由于三种染色体浓度异常所造成的。在附件数据中，并没有直接给出三种染色体（21 号、18 号、13 号）的染色体浓度。通过分析发现，附录中的 Z 值可以等价判断染色体浓度。Z 值如下定义。

$$Z = \frac{X - \mu}{\sigma} \quad (1)$$

直接理解某种染色体的 Z 值代表了个体中这个染色体比例与正常群体的差别，换句话说来说，当某种染色体的 Z 值越接近 0，说明该个体的该条染色体浓度与正常群体接近，说明没有异常。当 Z 值过大或者过小（离 0 越远）说明该号染色体浓度出现异常。在数据里面也就是 Q/R/S 列的数值，分别判断 13 号、18 号、21 号染色体浓度是否出现异常。

针对以上判断方法，我们可以对筛选出来的有效检测数据，这可以计算后续的检验误差。

(4) 筛选流程：




图 2 测序流程数据筛选流程图

(5) 数据初步分类

结合实际的题目背景以及后续建模要求，首先从 31 个列署筛选关键数据指标划分为三类：描述孕妇个体的指标数据、有关测序质量的指标数据、体现检测结果相关的指标数据。

类别	具体的列署以及对应的列编号
孕妇指标	年龄（C）、BMI（K）、孕周（J）、 身高（D）、体重（E）、孕产史（AC/AD）
测序质量	GC 含量（P）、过滤读段比例（AA）、 比对比例（M）、总读段数（L）
检测结果	Y 染色体浓度（V）、Y/X/Z 值（U/T/Q/R/S）、 非整倍体（AB）、胎儿健康（AE）

4.2 指标详解

题目多次提到一些专业名词，结合具体的数据，下文进行详细的解释说明：

1.BMI: BMI 是由身高和体重进行计算的，能够反映人体的健康性指数。初步分析发现，孕妇的 BMI 是较高的。在问题二的题目要求中说明，高 BMI 是影响 Y 染色体浓度达标时间点主要因素。高 BMI 孕妇因血液容量大、胎儿游离 DNA（cffDNA）被稀释，更易出现 Y 浓度达标延迟，是 NIPT 检测的“高风险人群”。因此，本文认为，研究可能特意纳入更多高 BMI 孕妇（样本偏向性），以重点分析其 Y 浓度规律，这种数据分布是合理的，并非异常值。

2.抽血检测说明：题目已经说明为了确保一次多检，多次多检。我们统计数据发现男胎的 267 个数据只有 260 个孕妇是存在多次多检的类型，仅 7 个孕妇是一次一检的检测类型。

检测类型	定义（基于 I 列“检测抽血次数”+H 列“检测日期”+B 列“孕妇代码”）
一次一检	同一个孕妇仅 1 个采血次数（I 值唯一），且该采血次数仅对应一次检测（同一个 I 值下仅 1 个 H 值）
多次多检	同一个孕妇有大于两个采血次数（I 值大于 2），且存在某些采血次数对应超过一次检测（存在不同的 I 值先有大于 1 个 H 值）

为了更好地理解孕妇从产检过程，本文以代码为 A002 的男胎孕妇进行解释说明：

检测日期	检测抽血次数	检测孕周
20240219	1	13w+6
20240310	2	16w+5
20240401	3	19w+5
20240429	4	23w+4
20240503	4	23w+4

20240429 当天，医护人员给这位孕妇采了第 4 次血（所以“检测抽血次数=4”），当时根据末次月经等信息算出的孕周是 23w+4（即“检测孕周=23w+4”）；到了 20240503，为了使检测结果更可靠（比如确认第一次检测的数值），没有再重新抽血，而是用 4 月 29 日采好的那管血再做了一次检测。

4.3 数据统计

本次 NITP 男胎孕妇一个有 267 人，1082 人次，检测孕周范围在 11 周至 29 周。发现男胎孕妇一共有三种生产方式：自然受孕、人工授精（IUI）、试管婴儿（IVF）。女胎孕妇的只有人工受孕、试管婴儿这两种妊娠方式。其中男胎孕妇 A084、A197 是人工授精；A107 和 A149 是试管婴儿。其中女胎孕妇 B080 和 B090 这两个孕妇是选择了试管婴儿。在本次数据集中自然受孕占比在 98%以上，那么在后续建模中，本文在后续建模主要讨论的是自然受孕的妊娠方式，其他妊娠方式本文会单独考虑。




图 3 怀孕次数与生产次数统计

进一步统计孕妇的怀孕次数和生产次数，发现接近一半的孕妇的怀孕次数为 1，怀孕超三次的孕妇占比将近 30%。接近 7 成的孕妇生产次数为 0，比怀孕次数增加了 20 个百分点。由于初次怀孕必然不会经历生产过程，可以推测出至少 20% 的孕妇经历过流产。进一步分析怀孕与生产次数，在怀孕次数为 2 的孕妇当中，经历过流产的比例为将近 40%；在怀孕次数大于等于 3 的孕妇当中，经历过流产的孕妇比例至少达到 76%，由于存在怀孕次数大于 3 且生产次数为 2 的情况，这种情况无法进行核实，因此未列入计算，说明流产比例可能会更高。在分析数据中，我们发现男胎孕妇 A021 在 2023/8/19 的生产次数出现异常，A033 在 2023/12/2 的怀孕次数有异常。

序号	孕妇代码	检测日期	检测抽血次数	检测孕周	怀孕次数	生产次数	胎儿是否健康
84	A021	2023/5/23	1	13w+4	≥3	2	是
85	A021	2023/6/14	2	16w+4	≥3	2	是
86	A021	2023/7/14	3	21w+1	≥3	2	是
87	A021	2023/8/19	4	26w	≥3	1	是
143	A033	2023/12/2	1	13w+2	2	0	是
144	A033	2023/12/30	2	17w+2	1	0	是
145	A033	2024/1/27	3	21w+1	1	0	是
146	A033	2024/2/24	4	24w+6	1	0	是

本题对数据并未说明其严谨性，上述明显错误，本文在此分析其是人工录入时出现错误，直接进行修正。

大多数孕妇第一次进行检测在 14 周之前，绝大多数在 17 周前完成第一次检测。在风险较低时期（12 周以前）开始 NIPT 检测的孕妇仅占比 25.9%。男胎孕妇 A156、A118 分别在 20 周、22 周才进行第一次检测，且仅检测一次。这个是为后续本文确立最佳检验时间提供了先前说明。

表 1 第一次孕检周数统计

第一次检验孕周数	计数	占比	第一次检验孕周数	计数	占比
11	9	3.4%	15	1	0.4%
12	60	22.5%	16	2	0.4%
13	118	44.2%	17	1	0.4%
14	74	27.7%	20、22	1、1	0.4%、0.4%

五、问题一的模型建立与求解

首先本题要求，分析男胎的 Y 染色体浓度与孕妇的孕周数和 BMI 等指标的相关关系特性，进一步给出对应的关系模型，最后需要检验该模型的显著性与准确性。通过查阅文献资料^[1]我们发现，医学检测中的指标之间的是复杂的且难以解释的，为了探寻这几个变量之间的关系模型，我们思考从三个维度进行关系的探寻，层层递进，我们希望得到组合关系模型。思路就是从数据特征出发，首先通过绘制散点图，初步探究每一个指标与 Y 染色体浓度的关系，接着通过相关性系数分析以及灰色关联分析将各个指标与 Y 染色体浓度的相关关联程度进行排序。更进一步我们希望输出各个指标共同与 Y 染色体浓度的关系，本文根据数据的特征，从第二个维度出发，创新构建“蒙特卡洛模拟-灰色预测”关系组合模型，最终给出我们的关系预测模型。最后，我们希望使用更加智能的方式，从第三个维度深入探寻各个指标与 Y 染色体浓度之间的关系。在每一个维度上构建的关系模型，我们都进行了显著性检验，分别分析了模型的显著性并在最后对此进行解释。

5.1 三维度探究关系模型的流程图




图 4 问题一流程图：关系模型的构建

5.2 指标的选取与相关性分析

Step1 指标的选取

题目已经明确说明需要考虑男胎孕妇的 BMI、孕妇的孕周数与 Y 染色体浓度之间的关系。查阅相关文献^[2]，多数研究表明发现孕妇年龄与 Y 染色体浓度也具有一定的关系，因此我们将孕妇年龄这个指标也纳入相关特性的考量范围内。结合题目以及附录 2 对数据的补充信息，我们针对同样分析下述指标与目标变量之间的关系。

表 2 其他指标及对应的隐藏信息

其他指标	隐藏信息解释
被过滤的读段数比例	过滤比例越高，有效测序数据越少。为后续关系模型排除低质量样本提供依据
在参考基因组上对比的比例	只有能比对到参考基因组的读段，才能被准确归类到 Y 染色体(用于浓度计算)，比对比例直接决定“有效读段基数”。
GC 含量	评估测序质量的重要指标，仅 P 列在 40%-60%时，浓度测量最准确。猜测具有非线性关系。

Step2 相关性分析

我们首先根据数据的特性以及分布特征选择合适的相关性分析方法，由于篇幅限制，本文绘制的各个指标的数据分布特征图放在附录内。多数呈现正态分布，因此本文在此选择 Pearson 相关系数分析方法。绘制了相关系数热力图。




图 5 指标之间的 Pearson 相关性性热力图

由上述分析发现各个指标与胎儿的 Y 染色体浓度的相关性并不高，我们无法直接下结论其具有较强的线性相关关系。从指标对比层面来看，孕妇的 BMI 和检测孕周与 Y 染色体浓度的相关性相较于其他指标来看会更强一点。这是符合我们原先的推测，但是我们仍然需要进一步这些指标与 Y 染色体浓度的相关关系。

5.3 维度一：判断是否具备线性关系




图 6 胎儿 Y 染色体浓度与 BMI（左）以及在参考基因组上的比例（右）的线性拟合

我们先从最简单的线性关系进行探索，由于篇幅限制，其他指标与 Y 染色体浓度的散点图放在附录内。这里展示了孕妇 BMI 与 Y 染色体浓度散点图，以及尝试了线性拟合。两个拟合的 R^2 值很小，说明了这个拟合效果并不好，因此我们需要挖掘其他的关系。除了线性相关程度，通过灰色关联度是一种衡量序列之间的几何形状相似度来判断关联程度也是合理的选择。

5.3.3 灰色关联分析进行相关程度排序

本题所涉及的数据具有小样本、信息不完全的特点。一方面，虽然提供了一定数量的数据，但相较于一些大规模的数据集而言，其样本量有限；另一方面，数据中可能存在一些缺失值或者不确定因素。灰色关联分析对于这类数据情况具有较好的适应性，它不需要大量的数据样本，也不要求数据满足特定的分布规律，能够在有限的信息下挖掘出变量之间的关联关系。通过计算关联度，以数值的形式直观地展示各个因素与参考序列之间的关联紧密程度。关联度越接近 1，表示该因素与参考序列的变化趋势越一致，关联程度越高；反之，关联度越接近 0，关联程度越低。这种量化的结果使得不同因素之间的关联程度可以进行直接比较和排序。为我们后文从第二个维度建立关系模型做铺垫。

Step1 确定分析序列

我们将胎儿的 Y 染色体浓度作为母序列，将男胎孕妇的 BMI、孕周数、年龄、在参考基因组上比对的比例这四个指标序列值分别作为子序列。此时考虑 1082 条数据样本。

$$\begin{cases} \text{母序列: } X_0 = (x_0(1), x_0(2), \dots, x_0(1082)) \\ \text{子序列: } X_i = (x_i(1), x_i(2), \dots, x_i(1082)) \quad i = 1, 2, 3, 4 \end{cases} \quad (2)$$

Step2 数据无量纲化处理:

采用均值化法: $x_i(k)' = \frac{x_i(k)}{\bar{x}_i}$ ，其中 $\bar{x}_i$ 是每个序列的平均值。

Step3 计算关联系数:

关联系数衡量了母序列（Y 染色体浓度）与每个比较序列在每个数据点的差异程度，公式为:

$$\xi_i(k) = \frac{\min_i \min_k |x_0'(k) - x_i'(k)| + \rho \max_i \max_k |x_0'(k) - x_i'(k)|}{|x_0'(k) - x_i'(k)| + \rho \max_i \max_k |x_0'(k) - x_i'(k)|} \quad (3)$$

其中， $|x_0'(k) - x_i(k)|$: 母序列与第 i 个子序列在第 k 个数据点的绝对差。

$\min_i \min_k |x_0'(k) - x_i'(k)|$: 所有子序列在所有数据点上与母序列最对差的最小值。

$\max_i \max_k |x_0'(k) - x_i'(k)|$: 所有子序列在所有数据点上与母序列绝对差的最大值。

ρ 为分辨系数，取一般值 0.5，这个的作用是调整最大和最小绝对差对关联系数的影响。

Step4 计算灰色关联度并排序

对比子序列的所有关联系数求平均值，得到一个单一的灰色关联度值，下表为采用 Python 求解出来各指标与 Y 染色体浓度有的灰色关联度值:

指标	灰色关联度值
孕妇的 BMI	0.774741
孕妇的孕周数	0.760019
孕妇年龄	0.770126
在参考基因组上比对的比例	0.780240

结果分析发现，这几个指标与母序列（Y 染色体浓度）的关联度值是较高的。通过这一步帮助我们筛选出那些关联度较高、对 Y 染色体浓度影响较大的变量。这些关键变量纳入灰色预测模型中为我们后续的建模，可以提高模型的预测精度和有效性。

5.4 维度二：基于灰色预测的单调性及指数型关系的探索

灰色预测模型可以将不确定因素视为灰色信息进行处理,通过对数据的生成和处理来弱化数据中的噪声和不确定性。与多元回归模型进行对比,灰色预测模型的计算过程相对简单,不需要复杂的数学推导(参数估计与假设检验)和大量的计算资源,在本题数据量不大的情况下,能够快速建立模型并进行预测,提高分析效率。因此在上文的基础上,本文构建灰色预测模型并针对该题的数据特性在此基础上提出创新。

5.4.1 灰色预测模型的初步构建

以上已经分析的单一指标的关系,以及对每一种指标与母序列之间的灰色关联度的值是较高的,理论上来说构建灰色预测模型是能够输出预测模型,下面将 $N-1$ 个指标作为自变量,预测主变量,也就是 Y 染色体浓度的趋势。具体包括以下步骤:

Step1 数据准备与预处理

首先我们确定序列,将 Y 染色体浓度作为主序列,将其他 4 个指标记作子序列:

$$\begin{cases} \text{主序列: } X_1^{(0)} = (x_1^{(0)}, x_1^{(0)}, \dots, x_1^{(0)}(1082)) \\ \text{子序列: } X_2^{(0)}, X_3^{(0)}, X_4^{(0)}, X_5^{(0)} \end{cases} \quad (4)$$

接着对所有序列进行一次累计生成,这一步是必要的,因为对于本次数据,随机误差较大,通过这个操作能够减少原始数据的随机性,揭示了数据内在的规律。

$$X_i^{(1)}(k) = \sum_{j=1}^k x_i^{(0)}(j), k = 1, 2, \dots, 1082 \quad (5)$$

于是我们就能够得到新的序列: $X_1^{(1)}, X_2^{(1)}, X_3^{(1)}, X_4^{(1)}$ 。接着对主序列 $X_1^{(1)}$ 进行邻值均值生成,得到新的序列 $Z_1^{(1)}$ 。

$$z_1^{(1)}(k) = 0.5 \cdot (x_1^{(1)}(k) + x_1^{(1)}(k-1)), k = 2, 3, \dots, 1082 \quad (6)$$

Step2 建立微分方程模型

GM(1,5) 的微分方程形式为:

$$\frac{dx_1^{(1)}}{dt} + ax_1^{(1)} = \sum_{i=2}^5 b_i x_i^{(1)} \quad (7)$$

方程描述了主序列与子序列之间的一种动态关系,我们的目标是求解出方程参数 a 和 b_i 。

Step3 求解参数

将微分方程离散化,使用最小二乘法来求解参数

构建矩阵 B 和向量 Y :

$$B = \begin{pmatrix} -z_1^{(1)}(2) & x_2^{(1)}(2) & x_3^{(1)}(2) & x_4^{(1)}(2) & x_5^{(1)}(2) \\ -z_1^{(1)}(3) & x_2^{(1)}(3) & x_3^{(1)}(3) & x_4^{(1)}(3) & x_5^{(1)}(3) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ -z_1^{(1)}(n) & x_2^{(1)}(n) & x_3^{(1)}(n) & x_4^{(1)}(n) & x_5^{(1)}(n) \end{pmatrix} \quad (8)$$

向量 Y 为:

$$Y = \begin{pmatrix} x_1^{(0)}(2) \\ x_1^{(0)}(3) \\ \vdots \\ x_1^{(0)}(n) \end{pmatrix} \quad (9)$$

求解阐述向量 $\hat{a}$: $\hat{a} = (B^T B)^{-1} B^T Y$
向量 $\hat{a}$ 的元素就是我们要求的参数:

$$\hat{a} = \begin{pmatrix} a \\ b_2 \\ b_3 \\ b_4 \\ b_5 \end{pmatrix} \quad (10)$$

Step4 建立最终模型与预测

将上述求得的参数带入微分方程得到最终的预测模型:

$$\begin{aligned} X^{(0)}(k) = & -0.023262 \cdot Z_0^{(1)}(k) - 0.004116 \cdot Z_1^{(1)}(k) - 0.026575 \cdot Z_2^{(1)}(k) \\ & - 0.010126 \cdot Z_3^{(1)}(k) + 0.036864 \cdot Z_4^{(1)}(k) \end{aligned} \quad (11)$$

上述模型求解得出的微分方程模型采用了后验差检验, 计算得到的后验差比 $C=0.97044$ 小概率误差概率 $P=0.526364$, 平均相对误差达到 40%, 模型表现并不良好, 显著性较低。

5.4.2 模型优化: “蒙特卡洛模拟-灰色预测”组合模型的构建

以上的检验说明该模型的预测是不精确的, 但是考虑了该模型的使用特点, 我们找到了问题所在, 在带入模型进行计算的时候, 我们直接带入了 1082 条数据。前面已经分析可得, 一共有 267 个男胎孕妇的数据, 同一个孕妇会有多条 NIPT 数据。对于不同孕妇而言, 本文可以假设她们的 NIPT 数据是没有直接的相关关系的。但是对于同一个孕妇而言, 她多次的 NIPT 数据肯定是不独立的, 但是前文是直接将这 1082 次数据直接带入灰色预测模型, 这些数据不具有相互独立性, 因此直接构建灰色预测模型的有效性较低。

基于本题遇到的问题, 本文创新思考将蒙特卡洛模拟与灰色预测相结合: 使用蒙特卡洛每次从每个孕妇的多条数据中随机抽取一条, 一共就是 267 条, 每一次都建立灰色预测子模型, 我们使用蒙特卡洛模拟随机生成了 1000 次抽取, 构建了 1000 次灰色预测子模型, 分别得到了 1000 个预测公式。

这些子模型与上述 5.4.1 的子模型公式进行修正。样本量由 1082 变为 267。这些方程最终收敛到如下关系预测模型方程。

$$\begin{aligned} X^{(0)}(k) = & -0.005699 \cdot Z_0^{(1)}(k) - 0.000034 \cdot Z_1^{(1)}(k) - 0.000063 \cdot Z_2^{(1)}(k) \\ & - 0.000141 \cdot Z_3^{(1)}(k) + 0.000365 \cdot Z_4^{(1)}(k) \end{aligned} \quad (12)$$

5.4.3 优化后的模型的显著性检验

我们继续使用后验差检验, 并且对各个指标进行检验, 得到如下的检验结果。

表 3 模型评估指标统计结果

评估指标	均值	标准差
后验差比 (C 值)	1.201027	0.076474
小误差概率 (P 值)	0.417640	0.036014

由于篇幅限制, 该模型对各个指标都进行了显著性检验, 包括检验系数的分布都放入附录。




图 7 优化后的灰色预测模型的拟合结果

由上图我们得到修正后的灰色预测模型的拟合结果，直接观察，大致的趋势是正确的，但是在关键的节点，走势具有明显异常。在带入模型的数据是已经经过降噪处理的，但是该还是具有较多的离群点。上表的模型显著性检验结果也表明该模型的准确性较低，表现结果仍然不满意。

我们知道灰色预测模型是更多是捕捉单调性以及指数型关系，那么从这个结果表示，在单调性以及指数型增长这个维度上说明 BMI、孕妇孕周数、被过滤调读段数比例、在参考基因组上对比的比例与胎儿的 Y 染色体浓度不具有指数型关系。那我们进一步分析，我们将使用更加智能的 XGboost 进一步捕捉这四个指标与胎儿的 Y 染色体浓度的非线性关系。下面从第三个维度进行关系捕捉与关系模型的建立。

5.5 维度三：XGBoost 非线性关系捕捉

5.5.1 非线性的关系模型的捕捉

上述针对线性关系探索以及指数型探索建立的关系模型，都没有办法得到一个显著性强的关系模型，因此我们思考使用更加智能的方式去捕捉他们之间的关系。将蒙特卡洛与 XGBoost 相融合，我们识别针对胎儿 Y 染色体的最重要的特征以及组合。

最重要的特征组合	特征值
检测孕周数值 在参考基因组上比对的比例	0.137143
年龄 在参考基因组上比对的比例	0.123164
孕妇 BMI 在参考基因组上比对的比例	0.117141
年龄 检测孕周数值	0.115904
孕妇 BMI 年龄	0.113318

5.5.2 模型的显著性检验

RMSE 是衡量模型预测值与实际值偏差程度的常用指标，反映预测结果的平均误差大小。本文使用 RMSE（均方根误差）比较不同的模型性能。根据模型检验结果说明这些智能模型的训练效果一般，模型不具备良好的性质。我们只能够根据此得到重要的特征值，如下图展示。能够定性地分析讨论这些指标的相关关系，但是我们无法得到一个特征突出的显示的表达式。可以下结论，这几个生物学指标一定具备复杂的关系。

模型	XGBoost	Random Forest	ElasticNet
RMSE	0.030497	0.02864	0.026251




图 8 指标及其交互关系的特征值

5.6 总结分析

以上从三个维度进行关系模型的探索，层层递进，并且针对每个模型给显著性检验。线性维度的关系探索，模型的表现极差；采用蒙特卡罗模拟和灰色预测的模型的关系模型，其误差也是较大的，就算拟合趋势较为一致，该模型也没有通过后验差检验，无法说明该模型具有较好的关系预测能力。考虑到生物学涉及到的指标间的交互关系往往较为复杂，人为或许很难选择到合适的模型，于是我们选择使用更加智能的模型，使用结合了蒙特卡罗模拟的 XGBoost 进行关系模型的构建，能够得到最佳特征。对于单个指标具备较好的显著性，但对于组合指标，发现其显著性较差。

出现这种情况我们可以从三个方面进行解释。首先数据我们已经进行了异常值处理、降噪处理等，并且考虑到样本的独立性，加入蒙特卡罗模拟。但这仍然不能够保证输入数据是较好的，因为本题数据是存在某些明显错误的，在本文的附录里面有说明。其次通过查阅相关文献^[3]，我们发现人体的相关检测中，很多人体的元素指标至今都没用显式的关系表达式。第三，检测本身就具有误差^[4]。如关系模型的构建，我们需要引入其他指标，并且需要更多的检测误差更小的检测数据。

六、问题二的模型建立与求解

6.1 思路总结

问题一已经证实了男胎孕妇的 BMI 与胎儿 Y 染色体浓度具有较大的相关关系。本题的总目标是寻找合适的分组，并且基于这个分组，找到每组的最佳检测时间，使得孕妇的风险最小。决策树回归是一种常见的分类方法，属于监督学习算法，它可以根据输入的特征自动寻找到最佳分裂点，形成分组区间，并且能够预测目标变量，从而为每组推荐最佳的 NIPT 时点。通过该模型可以输出分组区间以及最佳检测时间点。

在任何医学检测中，检测结果并非是全然正确的，检测必然会有误差。下述会根据题目定义的测序准则以及准确性的判断法，对附件数据进行统计分析，给出检测误差的详细定义。最后我们继续加入蒙特卡洛模拟，分析检测误差对于我们最终求解的结果的影响，检验模型的稳健性。

6.2 模型准备

6.2.1 风险最小解释

题目的最终目标是希望找到合适的分组以及每组的最佳检测时间节点，以减少孕妇的潜在风险。对于潜在风险，从实际情况出发，有如下两种场景。首先孕妇需要去检测胎儿是否具有异常，如果具有异常，那么要尽早的进行治疗。也就是说，要在时间上尽可能早地发现不健康的胎儿。但是我们还需要考虑检测的准确性，在第 4 章本文已经定义了测检成功的先决条件（GC 含量达到[0.4,0.6]），在成功检测的前提下，检测失误有两种情况：（1）孕妇本身怀有不健康的胎儿，但是检测结果表明一切正常；（2）如果孕妇本身怀有健康的胎儿，但是检测结果显示不正常。对于（1）情况，其所造成的后果较大，风险较高。总结来说，这个时间点要早，同时这个时间点，我们进行 NIPT 检测的准确性是较高的。

因此我们定义风险函数。本小节目标为：使得孕妇可能的潜在风险最小，并分析检测误差对结果的影响。为了减少潜在风险，应尽早发现不健康胎儿、减少检测误差（提高检测准确率）。

设检测时间风险系数

$$r_i = \begin{cases} 1, 1 \leq t \leq 12 \\ 2, 13 \leq t \leq 27 \\ 3, t \geq 28 \end{cases} \quad (13)$$

其中 t 为检测孕周， i 为检测序号， $1 \leq i \leq 1082$ 。为保证测序质量正常，NIPT 结果准确，对附件中 NIPT 数据进行如下约束：

$$\begin{cases} 0.4 \leq GC(i) \leq 0.6 \\ Y(i) \geq 0.04 \end{cases} \quad (14)$$

这里 $GC(i)$ 指的是 GC 含量， $Y(i)$ 指 Y 染色体浓度。

患病风险系数 s_i 定义如下：

$$s_i = \begin{cases} 0, \text{胎儿健康} \\ 1, \text{检测出染色体异常且胎儿不健康} \\ 2, \text{未检测出染色体异常但胎儿不健康} \end{cases} \quad (15)$$

检测准确度:

$$\omega_i = \begin{cases} 1, \text{检出非整倍体情况与健康状况吻合} \\ 0, \text{检出非整倍体情况与健康状况不吻合} \end{cases} \quad (16)$$

检测时间风险值 $R_j = \frac{1}{M_j} \sum_{i=1}^{M_j} r_i$, 其中 j 为 BMI 分组编号, M_j 为第 j 组内不健康胎儿数, 因为实际中应尽早发现不健康的胎儿, 所以该风险值考虑的是出生后患病的胎儿。

患病风险值 $S_j = \frac{1}{N_j} \sum_{i=1}^{N_j} s_i$, N_j 为第 j 组内检测数量。

检测准确率 $W_j = \frac{1}{N_j} \sum_{i=1}^{N_j} \omega_i$ 。

为实现题目目标, 应使(1)检测时间风险尽量小; (2)患病风险尽量小; (3)检测准确率尽量高。因此, 本题属于多目标优化问题, 总体目标为最小化潜在风险, 存在优化方向相反的目标。本文认为患病风险在所有潜在风险中影响较大, 对上述目标给予权重(0.3, 0.4, 0.3)。则本题目标的显示表达式为 $\min(0.3R_j + 0.4S_j - 0.3W_j)$ 。

6.2.2 数据准备

Step1 数据预处理

首先从数据集中提取关键变量, 我们需要以下列:

指标	解释
孕妇代码	唯一标识每个孕妇(格式为 A001, A002 这种)
孕妇 BMI	BMI 数值(同一孕妇不同时间的 BMI 可能不一样)
检测孕周	格式为 13w+4 或者 14w 这些, 需要先继进行数据转换
Y 染色体浓度	用于确定达标时间。
GC 含量	要先确保 GC 含量在 0.4~0.6 之间, 否则测序质量不高
检测抽血次数	孕妇的抽血次数, 若出现某位孕妇有重复的次数(比如说同一个孕妇出现了两个 4), 代表着该次抽血检验了多次

Step2 计算达标时间

对于每个孕妇, 按检测日期(格式为 20230409)排序多次检测记录, 首先要找到孕妇 GC 含量在 0.4~0.6 范围之内的数据行, 如果有同一管血验了多次的情况, GC 取平均值再判断, Y 染色体浓度也取平均值。找到 Y 染色体浓度首次达到或超过 0.04 的检测孕周。如果某孕妇从未达标, 排除该数据。

Step3 数据集构建

最终数据集应包含每个孕妇的 BMI 和达标时间(孕周)。

6.4 构建决策树回归模型

对于每个叶节点(即每个 BMI 组), 计算组内所有孕妇达标时间的 95th 百分位数(即 95%的孕妇在该孕周前达标)。这个百分位数即为该组的最佳 NIPT 时点, 以确保假阴性风险最小(因为 95%的孕妇此时已达标)

- (1) **特征选择:** 问题要求对 BMI 分组, 那么将 BMI 作为唯一特征
- (2) **目标变量:** 达标时间(孕周)
- (3) **模型训练:** 为了避免过拟合, 需要设置树的最大深度或最小叶节点样本数。树的分裂点将基于最小化均方误差(MSE)来选择。
- (4) **模型评估:** 检验模型的水平

6.5 提取分组和最佳的 NIPT 时点

Step1 提取分裂点: 从训练好的决策树中提取所有分裂点的 BMI 阈值。这些阈值将 BMI 划

分为多个区间（每个区间对应一个叶节点）。

Step2 分组定义：根据分裂点，定义 BMI 区间




图 9 决策树结构（用于 NIPT 达标时间分箱）

Step3 计算最佳 NIPT 时点：对于每个叶节点（即每个 BMI 组），计算组内所有孕妇达标时间的 95th 百分位数（即 95%的孕妇在该孕周前达标）。这个百分位数即为该组的最佳 NIPT 时点，以确保假阴性风险最小。

Step4 输出结果

分 组 ID	分组描述	样本数	最佳 NIPT 时点	相对孕期的时点
组 1	$BMI \leq 29.0$	16	20.32	20w+2 或 20w+3
组 2	$BMI \in (29.0, 30.3]$	23	16.27	18w+1 或 18w+2
组 3	$BMI \in (30.3, 31.1]$	22	20.71	20w+5
组 4	$BMI \in (31.1, 34.6]$	41	19.57	19w+4
组 5	$BMI > 34.6$ & 年龄 ≤ 29.5	15	21.7	21w+5
组 6	$BMI > 34.6$ & 年龄 > 29.5	12	20.41	21w+3

该表是我们根据男胎孕妇的分组结果，并且得到每组的最佳 NIPT 时点，。考虑到给出实际的检查天数，根据比例关系可以将改时间点转化为相对孕期的时间点，上表最后一列所示。




图 10 决策树分箱后各组的最佳 NIPT 检测时点示意图

6.6 模型检验及检测误差分析




图 11 决策过程中重要性排序

在本次分箱中，BMI(重要性 0.7932)和孕妇的年龄（重要性 0.2068）是关键特征。对于求解的结果，我们得到 R^2 值为-0.05,这个精度并不高，那么我们分析其原因，（1）输入变量个数较小，并且本文的实际数据就是样本量较小，那么我们确实可以说明本身影响这个 Y 染色体浓度达标时间肯定不仅与 BMI 有关，一定含有较多的其他因素影响。而且仅考虑 Y 染色体浓度的达标时间尽可能早。这也就是为什么说问题三是问题二的延伸，加入多个其他影响因素以及其他方面的限制标准。

七、问题三的模型建立与求解

问题三仍是给男胎孕妇的 BMI 进行合适的分组，并且给出每组的最佳 NIPT 时间点。问题三是问题二的延伸。首先相比于问题二中只考虑 BMI 作为影响 Y 染色体浓度最早达标浓度，问题三还需要考虑年龄、身高、体重等因素作为影响孕妇 Y 染色体浓度达标最早时间的影响因子。其次问题三还需要综合考虑检测误差、胎儿的 Y 染色体浓度达标比例，因此本题使用决策树进行风险分组，使用随机森林进行组内随机优化与预测。最后结合蒙特卡洛对模型进行验证以及检验误差分析。

7.1 模型准备

7.1.1 核心目标定义

本题的总目标仍然为不同特征的男胎孕妇推荐最佳的 NIPT 检测孕周，以最小化潜在风险。我们对总体的潜在风险主要包含两种风险。第一种是检测失败风险，即胎儿的 Y 染色体浓度小于 0.04 的概率。第二种是结果误判的风险，因胎儿的 DNA 浓度不足或者重量不佳导致假阴性或者假阳性风险。检测的失败风险和结构的误判风险是高度相关，浓度不足是导致误判的主要原因之一。那么相当于，最小化检测失败风险间接最小化了结果误判风险，也就最小化了总体的潜在风险。因此我们将该问题进行化简，在保证检测成功率的前提下，寻找最小检测孕周。

7.1.2 数据准备

Step1 数据清洗与过滤

首先要过滤掉那些 GC 值不在[0.4,0.6]的范围之内的检测记录，因为他们相当于没有成功进行 NIPT 的。然后要对部分指标进行编码操作。

指标	解释
孕妇代码	唯一标识每个孕妇（格式为 A001，A002 这种）
孕妇 BMI	BMI 数值（同一孕妇不同时间的 BMI 可能不一样）
检测孕周	格式为 13w+4 或者 14w 这些，需要先进行数据转换
Y 染色体浓度	用于确定达标时间。
GC 含量	要先确保 GC 含量在 0.4~0.6 之间，否则测序质量不高
检测抽血次数	孕妇的抽血次数，若出现某位孕妇有重复的次数（比如说同一个孕妇出现了两个 4），代表着该次抽血检验了多次

Step2 特征选择

分组特征(用于决策树): BMI,检测孕周,年龄,体重,身高等（检测前可知）。

预测特征(用于组内随机森林): 检测孕周,年龄等（BMI 不再需要，因其分组作用已完成）。

7.2 决策树的风险分组

本阶段目标是利用决策树生成具有不同风险特征（即不同浓度-孕周变化规律）的孕妇组别。

（1）模型建立

选择算法；选择特征：BMI，检测孕周，年龄、体重；目标：达标与否；超参数调优

（2）分组规则提取

模型训练后，决策树的每一个叶节点即为一个最终分组

（3）执行分组

为数据集中每个样本赋予一个组标签




图 12 决策数分组模型展示

7.3 基于随机森林的组内风险预测与优化

本阶段的目标是为每个决策树分组，建立一个精准模型，预测其失败风险随孕周的变化，并找到最佳时点。核心有三个步骤：

Step1 组内模型的建立

对于每一个组 g ，提取其所有样本，选择随机森林分类器。特征选择：检测孕周，年龄、身高、体重。目标就是达标与否，然后进行训练。

Step2 失败风险曲线生成

创建模拟数据：固定组 g 的其他特征，生成一系列孕周 t_i ；使用随机森林模型预测每个时间按下的达标概率 $P_g(\text{达标}/t_i)$ ，失败风险即为： $1 - P_g(\text{达标}/t_i)$ 。

Step3 寻找最佳时点

在失败风险曲线中，找到满足 $1 - P_g(\text{达标}/t_i) \geq 0.95$ 的最小孕周 t_i 。数学表达式：

$$t'_g = \min \{t_i | P_g(\text{达标}/t_i) \geq 0.95\}$$

7.4 结果分析与检验误差分析

7.4.1 结果分析

最终得到了 BMI 分组以及每组对应的最佳检测时点。

分组 ID	分组特征描述	理论最佳时点	稳健推荐时点	预期达标率
组 1	检测孕周数值 ≤ 17.43 & 体重 ≤ 87.25 & 孕妇 BMI ≤ 29.40	11.00	12.36	0.95
组 2	检测孕周数值 ≤ 17.43 & 体重 ≤ 87.25 & 孕妇 BMI > 29.40	12.30	16.04	0.95
组 3	检测孕周数值 ≤ 17.43 & 体重 > 87.25 & 年龄 ≤ 30.50	17.29	13.55	0.95
组 4	检测孕周数值 > 17.43 & 体重 ≤ 98.45 & 年龄 ≤ 35.00	17.57	17.57	0.95
组 5	检测孕周数值 > 17.43 & 体重 > 98.45	20.39	23.28	0.95

7.4.2 模型验证

评估模型推荐的最佳时点存在检测误差的稳健性。假设关键特征存在测量误差，为其添加随机噪声。使用蒙特卡洛模型算法模拟循环下述过程：为原始数据添加噪声，生成新的数据集；执行第一次决策树分组，为样本重新分配组标签；执行第二阶段组内预测，为每个组重新计算最佳时点。

最佳交叉验证数据：

检验指标名称	值
最佳交叉验证分数	0.8013
测试集准确率	0.8333
最佳参数	最大深度为 3

说明，检测误差对我们的模型结果的扰动不大，模型具备较好的稳健性。




图 13 各分组的风险曲线

八、问题四的模型建立与求解

问题四是在女胎孕妇的 NIPT 数据基础上进行分析的。女胎孕妇和女胎都是不携带 Y 染色体的，因此我们需要一种识别女胎异常的判定方法。对于数据的初步分析，我们可以得到一种初分类方法，但考虑到多因素交叉，以及存在误差干扰，不能够由简单的初分类方法进行判定，需要进一步探寻多指标之间的关系，得到判别方法。

8.1 模型准备

8.1.1 女胎数据的灰色关联分析

题目指出，将女胎孕妇的非整倍体，作为我们的判定结果。就是在女胎数据的 AB 列的结果作为判断结果，将下表指标作为判定的输入层。为了更加全面地考虑影响女胎异常的因素，我们首先将女胎是否异常作为母序列。该序列中 0 元素代表不患病，1 代表患病。指标序列值作为子序列，分别计算他们与母序列的灰色关联度。计算过程在前文已说明，在此只展示计算结果。

表 4 女胎相关指标与女胎是否异常的灰色关联度

指标	灰色关联度	指标	灰色关联度
孕妇的 BMI	0.9667818	GC 含量	0.967779428
检验孕周处理	0.956718398	13 号染色体的 Z 值	0.960091509
X 染色体浓度	0.971569169	18 号染色体的 Z 值	0.738565966
原始读段数	0.975018864	21 号染色体的 Z 值	0.961304212
在参考基因组上比对的比例	0.968225466	X 染色体的 Z 值	0.970379031

结果发现，这些指标与母序列的关联程度较大，为后文建立具体的判别分类模型做铺垫。

8.1.2 数据处理

处理手段如上节，在此不再阐述。

8.2 女胎异常判别模型的建立

8.2.1 基于数据判断的直接分类

在 GC 浓度正常的情况下，观察 X 染色体浓度，发现当女胎异常（存在 21 号、18 号和 13 号染色体非整倍体）时，染色体浓度区间为-0.066~0.024；女胎正常时，染色体浓度区间为-0.048~0.13。在数轴上绘制浓度区间，可发现：当浓度落在-0.066~-0.048 时，女胎必然是异常的；落在 0.024~0.13 时，女胎必然是正常的。进一步观察具体的染色体非整倍体，存在 13 号非整倍体的有 18 例，存在 18 号非整倍体的有 30 例，存在 21 号非整倍体的有 8 例。特别地，在不含 18 号非整倍体的异常女胎中，染色体浓度落在-0.045~0.008，与必然异常的区间没有交集。因此可以得出结论：当 X 染色体浓度落在-0.066~-0.048 时，女胎必然是异常的，且一定存在 18 号非整倍体；X 染色体浓度在 0.024~0.13 时，女胎必然是正常的。

8.2.2 基于 BP 神经网络的判别方法

那当 X 染色体浓度不落在 $[-0.066, 0.048]$ 以及 $[0.024, 0.13]$ 这两个区间上时，就不能够通过上述的直接分类方法进行判别胎儿是否异常。而这些变量之间的关系是较为复杂的，传统的线性判别分析等方法难以准确判断，于是本文选择 BP 神经网络的方法。

利用 BP 神经网络，随机选取数据集的 80% 数据为训练集，20% 为预测集。结合蒙特卡洛模拟的思想，选取多次。使用的指标为年龄、身高（厘米）、体重（千克）、检测孕周、孕妇 BMI、在参考基因组上比对的比例、重复读段的比例、GC 含量、13 号染色体的 Z 值、18 号染色体的 Z 值、21 号染色体的 Z 值、X 染色体的 Z 值、染色体的非整倍体。




图 14 BP 神经网络流程图

最终我们可以得到特征重要性排序

指标	特征重要性	指标	特征重要性
年龄	0.2359	GC 含量	0.2141
身高	0.2392	13 号染色体的 Z 值	0.2175
体重	0.2354	18 号染色体的 Z 值	0.2373
检测孕周	0.2299	21 号染色体的 Z 值	0.2239
孕妇 BMI	0.2412	X 染色体的 Z 值	0.2181
在参考基因组上比对的比例	0.2271		
重复读段的比例	0.2457		

8.2.3 模型检验

对该模型做检验，显示分类准确性较高。

检验指标	值	评价
平均准确率	0.6991	良
平均召回率	0.9810	好
平均 F1 分数	0.2029	一般
平均 AUC	1.0000	好

说明 BP 神经网络的有监督学习训练效果较好，每当输入一个女胎孕妇的相关的指标数据，模型可以输出一个异常检验结果，这个判别结果的准确率将近 70%

8.3 总结

总结来说，当 X 染色体浓度落在 $(-0.066, -0.048)$ 时，女胎必然是异常的，且一定存在 18 号非整倍体；当 X 染色体浓度在 $(0.024, 0.13)$ 时，女胎必然是正常的。对与其他情况，使用训练的 BP 神经网络判别模型输入孕妇指标值，那么可以较为准确的输出异常判别结果。

九、模型评价与改进方向

8.1 模型评价

(1) 在问题一中，难以捕捉较指标组合之间与 Y 染色体浓度的关系，我们尝试了很多方，从三个维度对指标与男胎 Y 染色体之间的关系进行描述。模型是全面的。

(2) 由于数据样本具备并不是相互独立的，本文创新提出“蒙特卡洛+灰色预测”方法进行第二维度关系的探索。模型具备较好的严谨性。

(3) 对于问题四中，首先基于数据集本身的分析，能够找到一阶分类方法，更进一步，使用 BP 神经网络进行训练，得到二阶判别方法。这个说明了模型具备较好的精度。

8.2 模型改进

(1) 本文的数据集信息含量较大，本文应当查阅资料，应当更加深入地分析数据集各个指标之间的关系。

(2) 问题一中除了横向分析，我们应该更加深入地探究每一个孕妇的关系，不过这是需要数据量更大、检测误差更小的数据集。

8.3 检测误差与健康状况（借助 AI 查询）

在 GC 浓度正常、Y 染色体浓度正常的情况下，检测到存在 21/18/13 号染色体的非整倍体，但胎儿出生结果健康的有 53 例，BMI 值处于 27~37 范围内。其中处于孕早期阶段（12 周前）的为 4 例，BMI 值处于 28~31 范围内。

查阅资料：检测结果与胎儿实际健康状况不一致，一般是出现假阳性结果或一过性染色体异常。假阳性指的是通过筛查手段检测到 21、18、13 号染色体非整倍体，但胎儿实际健康的情况，原因包括胎盘嵌合现象、母体因素干扰、检测误差等等。一过性染色体异常指的是，在胚胎发育早期（一般指妊娠 9-12 周），细胞分裂过程中可能出现一过性的染色体异常，因此早期检测时可能发现染色体非整倍体情况，在后续发育中，胚胎自身的修复机制或选择机制发挥作用，使得胎儿能够正常发育。

参考文献

- [1] 魏智芳, 侯东霞, 王晓华. 无创产前筛查中影响胎儿游离 DNA 浓度的因素研究进展[J]. 检验医学与临床, 2025, 22(6): 850-854, 859.
- [2] 薛莹, 丁洁, 贺权泽, 等. 孕妇年龄、孕周及体重指数对孕妇外周血中胎儿游离 DNA 比例的影响[J]. 中国产前诊断杂志 (电子版), 2017, 9(3): 5-10.
- [3] Lau T K, Cheung S W, Lo P S S, 等. Non-invasive prenatal testing for fetal chromosomal abnormalities by low-coverage whole-genome sequencing of maternal plasma DNA: review of 1982 consecutive cases in a single center[J]. Ultrasound in Obstetrics & Gynecology, 2014, 43(3): 254-264.
- [4] 于丹丹, 李奉瑾, 姚欣雨, 等. NIPT 在不同慎用人群胎儿常见染色体非整倍体异常检测中的效能分析[J]. 中国计划生育和妇产科, 2025, 17(3): 72-76, 82.
- [5] Doubao, Doubao-1.5, 字节跳动, 2025-09-07

附录

本文的附录包括 9 个部分，如下列表所示附录内容：

附录编码	内容说明
附录 1	支撑材料列表
附录 2	求解问题一的 Python 代码
附录 3	求解问题二的 Python 代码
附录 4	求解问题三的 Python 代码
附录 5	求解问题四的 Python 代码
附录 6	其他可视化展示

下面是每个附录详细的内容展示：

附录 1
包含内容说明：支撑材料列表
列表 1：所有 python 源文件 列表 2：参考文献

附录 2
包含内容说明：求解问题一的 Python 代码

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 from scipy import stats
4
5 # 设置中文字体显示
6 plt.rcParams['font.sans-serif'] = ['Microsoft YaHei']
7 plt.rcParams['axes.unicode_minus'] = False
8
9 # 1. 读取Excel文件
10 df = pd.read_excel("./data/data-total.xlsx")
11
12 # 2. 提取列数据：Y染色体浓度、孕妇BMI
13 y_chrom_conc = df["Y染色体浓度"] # Y染色体浓度
14 maternal_bmi = df["孕妇BMI"] # 孕妇BMI
15
16 # 3. 线性回归拟合
17 slope, intercept, r_value, p_value, std_err = stats.linregress(y_chrom_conc, maternal_bmi)
18
19 # 4. 绘制散点图 + 拟合直线
20 plt.figure(figsize=(10, 6)) # 设置图大小
21
22 # 散点图
23 plt.scatter(y_chrom_conc, maternal_bmi, color="skyblue", alpha=0.7, label="原始数据")
24
25 # 拟合直线
26 fit_line = slope * y_chrom_conc + intercept
27 plt.plot(y_chrom_conc, fit_line, color="red", linewidth=2,
28          label=f"线性拟合: y={slope:.4f}x + {intercept:.4f}\n$R^2$={r_value**2:.4f}, p={p_value:.4f}")
29
30 # 图表美化
31 plt.xlabel("Y染色体浓度", fontsize=12)
32 plt.ylabel("孕妇BMI", fontsize=12)
33 plt.title("Y染色体浓度与孕妇BMI的关系及线性拟合", fontsize=14)
34 plt.legend(fontsize=10)
35 plt.grid(linestyle="--", alpha=0.5)
36
37 # 5. 显示图表
38 plt.savefig('Y-BMI.png', dpi=400)
39 plt.show()
40
41 # 6. 打印拟合统计结果
42 print("=== 线性拟合结果 ===")
43 print(f"斜率 (slope): {slope:.4f}")
44 print(f"截距 (intercept): {intercept:.4f}")
45 print(f"相关系数 (r): {r_value:.4f}")
46 print(f"决定系数 ($R^2$): {r_value**2:.4f}")
47 print(f"p值 (p-value): {p_value:.4f}")
48 print(f"标准误差 (std_err): {std_err:.4f}")
```

```

1 import pandas as pd
2 import matplotlib.pyplot as plt
3 from scipy import stats
4
5 # 设置中文字体显示
6 plt.rcParams['font.sans-serif'] = ['Microsoft YaHei']
7 plt.rcParams['axes.unicode_minus'] = False
8
9 # 1. 读取Excel文件
10 df = pd.read_excel("../data/data-total.xlsx")
11
12 # 2. 提取列数据: Y染色体浓度、孕妇BMI
13 y_chrom_conc = df["Y染色体浓度"] # Y染色体浓度
14 maternal_bmi = df["孕妇BMI"] # 孕妇BMI
15
16 # 3. 线性回归拟合
17 slope, intercept, r_value, p_value, std_err = stats.linregress(y_chrom_conc, maternal_bmi)
18
19 # 4. 绘制散点图 + 拟合直线
20 plt.figure(figsize=(10, 6)) # 设置图大小
21
22 # 散点图
23 plt.scatter(y_chrom_conc, maternal_bmi, color="skyblue", alpha=0.7, label="原始数据")
24
25 # 拟合直线
26 fit_line = slope * y_chrom_conc + intercept
27 plt.plot(y_chrom_conc, fit_line, color="red", linewidth=2,
28         label=f"线性拟合: y={slope:.4f}x + {intercept:.4f}\n$R^2$={r_value**2:.4f}, p={p_value:.4f}")
29
30 # 图表美化
31 plt.xlabel("Y染色体浓度", fontsize=12)
32 plt.ylabel("孕妇BMI", fontsize=12)
33 plt.title("Y染色体浓度与孕妇BMI的关系及线性拟合", fontsize=14)
34 plt.legend(fontsize=10)
35 plt.grid(linestyle="--", alpha=0.5)
36
37 # 5. 显示图表
38 plt.savefig('Y-BMI.png', dpi=400)
39 plt.show()
40
41 # 6. 打印拟合统计结果
42 print("=== 线性拟合结果 ===")
43 print(f"斜率 (slope): {slope:.4f}")
44 print(f"截距 (intercept): {intercept:.4f}")
45 print(f"相关系数 (r): {r_value:.4f}")
46 print(f"决定系数 ($R^2$): {r_value**2:.4f}")
47 print(f"p值 (p-value): {p_value:.4f}")
48 print(f"标准误差 (std_err): {std_err:.4f}")

```

附录 3

包含内容说明：求解问题二的 Python 代码

```
1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import re
5 import seaborn as sns
6 from tqdm import tqdm
7 import pickle
8 import os
9 from scipy import stats
10 from scipy.signal import savgol_filter
11 import xgboost as xgb
12 from sklearn.model_selection import train_test_split, cross_val_score, GridSearchCV
13 from sklearn.metrics import mean_squared_error, r2_score, mean_absolute_error
14 from sklearn.preprocessing import StandardScaler, PolynomialFeatures
15 from sklearn.feature_selection import SelectKBest, f_regression, mutual_info_regression
16 from sklearn.ensemble import RandomForestRegressor
17 from sklearn.linear_model import ElasticNet
18 import shap
19
20 # 设置中文显示
21 plt.rcParams["font.family"] = ["Microsoft YaHei"]
22 plt.rcParams["axes.unicode_minus"] = False # 解决负号显示问题
23
24 # 1. 数据预处理函数
25 def convert_gestational_week(week_str):
26     """将孕周字符串转换为数值型周数"""
27     if pd.isna(week_str):
28         return None
29     # 正则匹配周数和天数
30     match = re.match(r'(\d+)w(?:\+(\d+))?', str(week_str))
31     if match:
32         weeks = int(match.group(1))
33         days = int(match.group(2)) if match.group(2) else 0
34         return round(weeks + days / 7.0, 3) # 转换为总周数并保留3位小数
35     return None
36
37 def remove_outliers_iqr(df, columns, factor=1.5):
38     """
39     使用IQR方法去除异常值
40     factor: 控制异常值检测的严格程度, 通常为1.5
41     """
42     df_clean = df.copy()
43     for col in columns:
44         Q1 = df_clean[col].quantile(0.25)
45         Q3 = df_clean[col].quantile(0.75)
46         IQR = Q3 - Q1
47         lower_bound = Q1 - factor * IQR
48         upper_bound = Q3 + factor * IQR
49
50         # 保留在范围内的数据
51         df_clean = df_clean[(df_clean[col] ≥ lower_bound) & (df_clean[col] ≤ upper_bound)]
52
53     print(f"异常值处理: 原始数据{len(df)}行, 处理后{len(df_clean)}行")
54     return df_clean
```


附录 4

包含内容说明：求解问题三的 Python 代码

```
1 # 3. 第一阶段：基于决策树的风险分组
2 print("\n3. 第一阶段：基于决策树的风险分组 ... ")
3 # 划分训练测试集
4 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
5
6 # 调整决策树参数，避免过拟合
7 param_grid = {
8     'max_depth': [3, 4],
9     'min_samples_split': [20, 30],
10    'min_samples_leaf': [10, 15]
11 }
12
13 dt = DecisionTreeClassifier(random_state=42)
14 grid_search = GridSearchCV(dt, param_grid, cv=5, scoring='accuracy')
15 grid_search.fit(X_train, y_train)
16
17 print(f"最佳参数: {grid_search.best_params_}")
18 print(f"最佳交叉验证分数: {grid_search.best_score_: .4f}")
19
20 # 使用最佳参数训练决策树
21 best_dt = grid_search.best_estimator_
22 y_pred = best_dt.predict(X_test)
23 print(f"测试集准确率: {accuracy_score(y_test, y_pred): .4f}")
24
25 # 提取决策树分组规则
26 df_final['Group_Label'] = best_dt.apply(X)
27
28 # 获取所有叶节点
29 n_nodes = best_dt.tree_.node_count
30 children_left = best_dt.tree_.children_left
31 children_right = best_dt.tree_.children_right
32 feature = best_dt.tree_.feature
33 threshold = best_dt.tree_.threshold
34
35 # 找到所有叶节点
36 is_leaves = np.zeros(shape=n_nodes, dtype=bool)
37 stack = [(0, -1)] # 初始节点
38 while len(stack) > 0:
39     node_id, parent_depth = stack.pop()
40     is_leaves[node_id] = (children_left[node_id] == children_right[node_id])
41
42     if not is_leaves[node_id]:
43         stack.append((children_left[node_id], parent_depth + 1))
44         stack.append((children_right[node_id], parent_depth + 1))
45
46 leaf_nodes = np.where(is_leaves)[0]
47 print(f"叶节点数量: {len(leaf_nodes)}")
48
49 # 提取每个叶节点的规则
50 def extract_rules_from_leaf(node_id, tree, feature_names):
51     left = tree.tree_.children_left
52     right = tree.tree_.children_right
53     threshold = tree.tree_.threshold
54     features = [feature_names[i] for i in tree.tree_.feature]
55
56     rule_parts = []
57     while node_id != 0:
58         parent = np.where((left == node_id) | (right == node_id))[0][0]
59         if left[parent] == node_id:
60             rule_parts.append(f"{features[parent]} ≤ {threshold[parent]:.2f}")
61         else:
62             rule_parts.append(f"{features[parent]} > {threshold[parent]:.2f}")
63         node_id = parent
64
65     return " & ".join(reversed(rule_parts))
66
67 # 创建分组规则映射
68 group_rules_map = {}
69 for node_id in leaf_nodes:
70     rule = extract_rules_from_leaf(node_id, best_dt, feature_names)
71     group_rules_map[node_id] = rule
72     print(f"叶节点 {node_id}: {rule}")
```


附录 5

包含内容说明：求解问题四的 Python 代码

```
1 # 蒙特卡洛模拟
2 for i in range(n_iterations):
3     X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size=0.2, random_state=i,
4                                                         stratify=y)
5     model = Sequential([
6         keras.layers.Dense(24, activation='relu', input_shape=(X_train.shape[1],)),
7         keras.layers.Dense(12, activation='relu'),
8         keras.layers.Dense(1, activation='sigmoid')
9     ])
10    model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])
11
12    class_weight = {0: 1., 1: len(y_train[y_train==0]) / len(y_train[y_train==1])}
13    model.fit(X_train, y_train, epochs=50, batch_size=32, verbose=0, class_weight=class_weight)
14
15    y_pred_prob = model.predict(X_test).flatten()
16    y_pred = (y_pred_prob > 0.5).astype(int)
17
18    accuracies.append(accuracy_score(y_test, y_pred))
19    recalls.append(recall_score(y_test, y_pred))
20    f1_scores.append(f1_score(y_test, y_pred))
21
22    fpr, tpr, _ = roc_curve(y_test, y_pred_prob)
23    auks.append(auc(fpr, tpr))
24
25    weights = model.layers[0].get_weights()[0]
26    feature_importances.append(np.mean(np.abs(weights), axis=1))
27
28 # 计算平均性能指标和特征重要性
29 mean_accuracy = np.mean(accuracies)
30 mean_recall = np.mean(recalls)
31 mean_f1 = np.mean(f1_scores)
32 mean_auc = np.mean(auks)
33 mean_feature_importance = np.mean(feature_importances, axis=0)
34
35 # 训练最终模型（使用全部数据）
36 final_model = Sequential([
37     keras.layers.Dense(24, activation='relu', input_shape=(X_scaled.shape[1],)),
38     keras.layers.Dense(12, activation='relu'),
39     keras.layers.Dense(1, activation='sigmoid')
40 ])
41 final_model.compile(optimizer='adam', loss='binary_crossentropy', metrics=['accuracy'])
42
43 # 计算最终模型的类别权重
44 final_class_weight = {0: 1., 1: len(y[y==0]) / len(y[y==1])}
45
46 # 训练最终模型
47 final_model.fit(X_scaled, y, epochs=50, batch_size=32, verbose=0, class_weight=final_class_weight)
48
49 # 保存最终模型
50 final_model.save('models/final_model.h5')
51 print("最终模型已保存为 models/final_model.h5")
```

附录 6

包含内容说明：其他可视化展示




图 15 指标数据特征分布图




图 16 所选指标与胎儿 Y 染色体浓度的关系散点图及趋势拟合




图 17 基于蒙特卡洛模拟的灰色预测模型显著性检验的系数分布




图 18 发展系数（左）和驱动系数（右）与累计均值变化




图 19 模型后验差显著性检验的相关检验系数累计均值变化